

Práctica Análisis Exploratorio con Visualizaciones y Librería Personalizada

Aldo Alberto Rodríguez Flores

El código de este proyecto se encuentra en link de GitHub

<https://github.com/aldorodev/practica3>

El objetivo de este informe es profundizar en el análisis exploratorio de datos mediante la creación de una **librería personalizada de visualización** con funciones reutilizables, aplicando buenas prácticas de desarrollo y análisis estadístico, se utilizó el *dataset* **CTG.csv** (Cardiotocografía), un conjunto de datos utilizado para el monitoreo fetal

Se utilizaron seis funciones de pre-processing para transformar el conjunto de datos, En la librería `ctg_viz/preprocessing.py` se encuentran las funciones:

def eliminar_columnas_con_nulos(df: pd.DataFrame, umbral_porcentaje: float = 0.20) -> pd.DataFrame:

Con esta función se buscamos descartar columnas enteras si la proporción de valores nulos supera un umbral definido, ayudando a eliminar características de baja calidad. Específicamente esta función compara el conteo de nulos por columna con el umbral calculado (20% del total de filas por defecto).

Resultado: No se eliminó ninguna columna, ya que ninguna excedía el umbral del 20% de nulos⁶.

def imputar_valores(df: pd.DataFrame, col_num: Iterable[str] = None, col_cat: Iterable[str] = None, metodo_num: str = "mediana") -> pd.DataFrame:

Con esta función se rellenan los valores nulos NaN restantes después del filtrado inicial, asegurando la completitud del *dataset*. para las variables numéricas se Imputó con la mediana para mitigar el impacto de posibles valores extremos (*outliers*) y las variables categóricas se Imputó con la moda.

Resultado: Se imputaron valores en todas las columnas con nulos (máximo 3 nulos por

columna numérica como LBE, AC, Max), lo que resultó en un *dataset* con 0 nulos restantes ósea el 100% de completitud .

def verificar_unicos_outliers(df: pd.DataFrame) -> List[str]:

Con esta función se clasifican las columnas numéricas para determinar cuáles son aptas para el análisis de *outliers* basado en el rango Inter cuartílico (IQR).

Se presenta como columna APTA (Continua) si tiene más de 10 valores únicos. De lo contrario, se marca como NO APTA (Discreta/Categórica), ya que el análisis IQR no es estadísticamente apropiado para las categóricas.

Resultado: 20 columnas fueron clasificadas como APTAS (Continuas) ¹⁴, incluyendo métricas clave del CTG como LBE, ASTV, MSTV, Width, y 17 fueron No Aptas (Discretas) ¹⁵.

def detectar_outliers_iqr(df: pd.DataFrame, columnas: Iterable[str] = None) -> Dict[str, Dict[str, float]]:

Con esta función se identifica y cuantifica la existencia de valores atípicos en las columnas APTAS. Aquí se **calcula el rango intercuartílico (IQR)** ($Q3 - Q1$) y define los límites superior e inferior como $Q1 - 1.5 \text{ IQR}$ y $Q3 + 1.5 \text{ IQR}$.

def capping(df: pd.DataFrame, columnas: Iterable[str] = None) -> pd.DataFrame:

Con esta función se corrigen los *outliers* para limitar su impacto, aumentando la robustez del modelo, se reemplaza los valores que caen por debajo del límite inferior con el límite inferior, y los valores que superan el límite superior con el valor del límite superior (método *capping* o limitación).

Resultado: De esta manera se logra limitar los altos números de *outliers* en columnas con alta dispersión, como FM (311 valores limitados a 5.00) y ALTV (310 valores limitados a 27.50).

En la librería `ctg_viz/categorization.py` se encuentran la función:

`def check_data_completeness_AldoAlbertoRodriguezFlores(df: pd.DataFrame) -> pd.DataFrame:`

Con esta función se genera una tabla de resumen final con todas las métricas de calidad de datos y la clasificación de variables. Aquí se consolida la clasificación (Continua, Discreta, Categórica), la completitud (Nulos, Porcentaje de Completitud) y la dispersión (IQR, Límites y Conteo de Outliers) en un solo *DataFrame*.

En la librería `ctg_viz/utils.py` se encuentran las funciones:

`columnas_numericas(df: pd.DataFrame) -> List[str]`


Esta función identifica y retorna una lista con los nombres de todas las columnas en el DataFrame (df) cuyos tipos de datos son numéricos (enteros, flotantes, etc.).

`columnas_categoricas(df: pd.DataFrame) -> List[str]`

Esta función identifica y retorna una lista con los nombres de todas las columnas en el DataFrame (df) cuyos tipos de datos son categóricos. Esto incluye columnas de tipo 'object' y el tipo 'category' de pandas.

Gráficas


Histograma



La gráfica muestra que los valores de ASTV son altos en los casos normales, bajos en los casos sospechosos y muy parecidos a los normales en los casos patológicos.

Esto significa que ASTV sirve bien para identificar cuando un caso es sospechoso, pero no es suficiente por sí solo para diferenciar entre un caso normal y uno patológico.

Multi Boxplots



Estos gráficos comparan tres medidas del latido fetal (LBE, ALTV y MLTV) entre las clases del objetivo NSP.


En LBE, la clase sospechosa (2.0) muestra valores más altos que las clases normal (1.0) y patológica (3.0), lo que indica mayor frecuencia cardiaca basal en esos casos.

En ALTV, se ve una diferencia muy marcada: la clase normal tiene valores muy bajos, mientras que las clases sospechosa y patológica muestran valores mucho más altos, por lo que esta variable ayuda claramente a distinguirlas.

En MLTV, la clase normal tiende a tener valores mayores que las otras dos, lo que sugiere mayor variabilidad del ritmo cardíaco, y reduce en casos sospechosos y patológicos.

En conjunto, estas tres variables muestran patrones distintos que ayudan a separar mejor las clases, especialmente con ALTV y MLTV.


Barras Horizontales



La gráfica muestra cuántos casos hay en cada categoría de NSP. La clase 1.0 (normal) es, por mucho, la más frecuente, con más de 1600 registros. La clase 2.0 (sospechosa) aparece mucho menos, con un poco más de 300 casos, y la clase 3.0 (patológica) es la menos común, con alrededor de 200 casos.

Esto indica que el conjunto de datos está desbalanceado, ya que la mayoría de los registros son normales y hay muy pocos casos sospechosos y patológicos, algo importante a considerar al entrenar modelos de machine learning.

Líneas




La gráfica muestra cómo cambian los valores de ASTV conforme avanzan los registros, simulando un paso del tiempo. Se observan variaciones constantes, con periodos donde ASTV sube hasta valores altos (alrededor de 60 a 80) y otros donde baja a valores más bajos (20 a 30).

Aunque hay muchos picos y caídas, se aprecia un patrón general: un tramo inicial con valores moderados y altos, una fase central con una caída notable, y finalmente un nuevo aumento hacia el final.

Esto indica que ASTV tiene un comportamiento altamente variable, sin una tendencia lineal clara, pero con ciclos donde tiende a subir y bajar a lo largo del tiempo simulado.

Dot Plots




La gráfica compara los valores de ASTV entre las clases 1 (normal) y 3 (patológica). Ambos grupos tienen puntos distribuidos en rangos parecidos, especialmente entre 50 y 80, lo que hace que visualmente se parezcan mucho.

Sin embargo, la clase 3 muestra dos grupos: uno principal con valores altos (similar a la clase 1) y otro más pequeño con valores más bajos (alrededor de 20–40).

Esto confirma que ASTV por sí solo no distingue bien entre normal y patológico, porque gran parte de sus valores se superponen, aunque la clase 3 tiene algunos casos más dispersos y extremos.

Densidad




La gráfica muestra cómo se distribuyen los valores de ASTV en cada clase de NSP: la clase 1 concentra valores más bajos (entre 20 y 60), mientras que las clases 2 y 3 tienden a tener valores más altos (entre 60 y 80), lo que indica que el ASTV varía claramente entre clases y podría ayudar a diferenciarlas.

Conforme aumenta el nivel de riesgo (NSP), también aumentan los valores típicos de ASTV. Además, la clase 1 muestra una distribución más amplia y dispersa, mientras que las clases 2 y 3 son más compactas.


En conjunto, la gráfica ayuda a visualizar cómo cada clase presenta patrones distintos en el comportamiento del ASTV.

Violín



La gráfica muestra cómo se distribuyen los valores de ASTV para cada clase de NSP usando violines y puntos individuales: la clase 1 presenta valores más variados y dispersos, mientras que las clases 2 y 3 se concentran en rangos más altos, especialmente por encima de 60. Los puntos reflejan cada observación real, permitiendo ver la densidad y la variabilidad dentro de cada clase. En conjunto, se observa un claro incremento en los valores típicos de ASTV conforme aumenta la clase NSP.

Heatmap



Este heatmap muestra la fuerza y dirección de las correlaciones entre todas las variables usando el método Spearman: los colores rojos indican correlaciones positivas más fuertes y los azules correlaciones negativas. La diagonal en rojo intenso representa la correlación perfecta de cada variable consigo misma. Se observan varios grupos de variables que tienden a moverse juntas, lo que ayuda a identificar patrones, redundancias y posibles relaciones importantes dentro del conjunto de datos.

En general, el mapa permite ver rápidamente qué variables podrían estar más relacionadas con el comportamiento de otras, incluida la variable NSP.

El color más rojo = relación positiva fuerte

El color más azul = relación negativa fuerte.

Conclusiones

La Completitud del 100% fue garantizada; aunque el *dataset* inicial presentaba un número muy bajo de valores nulos, principalmente en metadatos y en algunas columnas numéricas, la aplicación estratégica de `imputar_valores` con la mediana y la moda eliminó la totalidad de estos faltantes.

La Robustez Estadística fue el mayor logro, ya que se identificó la dispersión extrema en variables claves como ALTV, MLTV y FM; el uso del método capping basado en el IQR limitó exitosamente estos valores atípicos, un paso indispensable para prevenir que errores de medición o valores extremos irreales sesguen el rendimiento de los modelos de *machine learning*.

Finalmente, la Clasificación de Variables se ejecutó correctamente mediante la función de chequeo final, separando claramente las mediciones Continuas de los contadores de eventos Discretos, lo que facilita y guía la selección adecuada de modelos predictivos o algoritmos de clasificación en la fase de modelización. En resumen, el *dataset* resultante no solo está completo, sino que también está estadísticamente limpio y preparado de manera óptima para la fase de modelización predictiva.

Respecto a las graficas se puede concluir que la variable ASTV (Variabilidad a Corto Plazo) es pobre discriminador entre los estados fetal Normal 1 y Patológico 3 debido a la superposición de sus rangos de valores. En contraste, la combinación de ALTV y MLTV (Variabilidad a Largo Plazo) es mucho más efectiva, ya que la clase normal presenta un patrón opuesto (ALTV bajo, MLTV alto) al de las clases de riesgo.